

SVEUČILIŠTE U ZAGREBU
FAKULTET ELEKTROTEHNIKE I RAČUNARSTVA

SEMINAR

**Metodološki okvir za razvoj modela strojnog učenja za
predviđanje protoka rijeka u Hrvatskoj**

Ivan Dujmić

Voditelj: *Ljiljana Brkić*

Zagreb, travanj, 2026.

Sadržaj

1.	Uvod	3
2.	Temeljni koncepti hidrološkog predviđanja.....	4
3.	Pregled suvremenih modela hidrološkog predviđanja.....	5
3.1	Procesni (fizički utemeljeni) modeli.....	5
3.2	Konceptualni modeli.....	5
3.3	Podatkovno vođeni modeli.....	5
3.3.1	Rekurentne neuronske mreže (mreže dugog kratkoročnog pamćenja).....	6
3.3.2	Unaprijedne neuronske mreže (višeslojni perceptron za regresiju)	6
3.3.3	Slučajne šume	6
3.3.4	Konvolucijske neuronske mreže	7
3.3.5	Transformer modeli.....	7
3.4	Hibridne arhitekture	7
4.	Izvori i dostupnost podataka	8
5.	Analiza i opis podataka	9
6.	Metodološki okvir.....	12
6.1	Definicija problema	12
6.2	Odabir modela.....	12
6.3	Priprema podataka.....	14
6.4	Evaluacija.....	15
6.5	Ostali izazovi i zanimljivosti u modeliranju.....	16
7.	Zaključak.....	17
8.	Sažetak	18
9.	Literatura	19
10.	Prilozi	21
10.1	Prilog A – Izlučene informacije iz analiziranih radova.....	21

1. Uvod

Protok i vodostaj bitni su pokazatelji stanja vodenih sustava. Njihovo praćenje i predviđanje omogućuje pravovremeno pripremanje za poplave, bolje upravljanje vodenim resursima i efikasnije korištenje hidroelektrana.

Razvijeni su mnogi modeli za predviđanje protoka rijeka koji se međusobno razlikuju prema metodološkom pristupu, ulaznim podacima i razini složenosti. Tradicionalni modeli bazirani su na fizičkim procesima i zakonima dok se noviji modeli oslanjaju na povijesne podatke i veze među varijablama kako bi izvodili predviđanja.

U Hrvatskoj se za predviđanje protoka rijeka trenutačno koristi fizikalni model (DHMZ, 2026). Napretkom područja strojnog i dubokog učenja, uz akumulaciju velike količine hidroloških i klimatskih podataka, modeli dubokog učenja postižu sve veću točnost te postaju sve zastupljeniji u praksi. Osim visoke točnosti na mjerenim slivovima, takvi modeli postižu dobru točnost i na nemjerenim slivovima, a uz to i dobre performanse u predviđanju ekstremnih uvjeta.

S obzirom na navedeno, modeli strojnog, odnosno dubokog učenja predstavljaju potencijalno poboljšanje za predviđanje protoka rijeka u Hrvatskoj. Cilj ovoga rada je identificirati modele koji predstavljaju najveći potencijal za postizanje dobrih performansi i postaviti metodološki okvir za njihovu izradu i evaluaciju. U tu svrhu provodi se analiza postojećih rješenja i dostupnih podataka vezanih za predviđanje protoka rijeka.

2. Temeljni koncepti hidrološkog predviđanja

Sliv je područje s kojeg sva voda otječe prema nekoj točki.

Oborina je primarni izvor vode u hidrološkom sustavu. Izražava se u mm (milimetara visine ili litara vode po kvadratnom metru), a mjeri se kišomjerima. Za sliv se uzimaju podatci s prikladnog bliskog kišomjera ili kombinacija njih nekoliko. Oborina otječe površinski, infiltrira u tlo ili evaporira.

Snijeg je oblik oborine koji se akumulira i topi te time u sustav uvodi odgođeni dotok vode.

Vlažnost tla mijenja oblik i intenzitet otjecanja tako što mijenja sposobnost tla u prihvaćanju vode (infiltracija). Zasićeno tlo dovodi do većeg površinskog otjecanja u prisutnosti oborina dok suho tlo dopušta infiltraciju. Vlažnost tla omogućuje formiranje baznog toka.

Evapotranspiracija je proces izlaza vode iz sustava kroz evaporaciju i transpiraciju biljaka. Na evapotranspiraciju najviše utječu sunčevo zračenje, temperatura zraka, vlažnost zraka i vjetar.

Temperatura zraka je važna varijabla zbog utjecaja na evapotranspiraciju, topljenje snijega i druge varijable. Bilježi se u °C.

Protok je rezultat svih hidroloških procesa u slivu. Opisuje količinu vode koja prolazi kroz presjek vodotoka u jedinici vremena, a izražava se u m^3/s . Ovo je varijabla koju modeli nastoje predvidjeti. U nekim slučajevima je potrebno uzeti u obzir i dotok u sliv iz uzvodnih dijelova ili pritoka, koji se mjere na hidrološkim postajama ili se također predviđaju modelima.

Vodostaj je visina vodene površine u rijeci i može se koristiti umjesto protoka zbog lakšeg mjerenja i jednostavne pretvorbe u protok.

Ekstremni događaji se odnose na poplave i suše. Jedan su od glavnih razloga razvoja modela predviđanja protoka.

3. Pregled suvremenih modela hidrološkog predviđanja

Pregledom literature te časopisa koji se nabrajaju u poglavlju 6.2 izdvojene su i opisane kategorije modela hidrološkog predviđanja te osnovnih oblika modela strojnog i dubokog učenja korištenih u hidrologiji.

3.1 Procesni (fizički utemeljeni) modeli

Procesni modeli eksplicitno rješavaju fizikalno utemeljene jednačbe koje opisuju hidrološke procese kako bi simulirali sustav. Parametri modela se mogu interpretirati kao fizikalna svojstva te se idealno minimalno kalibriraju za različite situacije.

Temelje se na zakonima očuvanja mase, energije i linearnog momenta fluida te uključuju procese kao što su infiltracija, površinsko i podzemno otjecanje, evapotranspiracija i dr.

Dijelimo ih prema prostornoj diskretizaciji na agregirane modele koji sliv agregiraju u jednu točku i koriste prosječne vrijednosti, polu-distribuirane modele koji sliv dijele na nekoliko područja i potpuno distribuirane modele koji sliv dijele na mrežu i time ostvaruju najrealističniju simulaciju, ali uz najveće zahtjeve.

Neki procesni modeli su SWAT, HEC-HMS, MIKE SHE, DHSVM, a razlikuju se prema razini prostorne diskretizacije, složenosti fizikalnih procesa, vrsti ulaznih podataka i namjeni.

Procesni modeli su vrlo interpretabilni i jasan je utjecaj pojedinih varijabli na rezultat.

Fizički utemeljeni modeli su računalno zahtjevni, a također se javlja problem teške dostupnosti preciznih ulaznih podataka koji su potrebnih za simuliranje sustava ovim modelima.

3.2 Konceptualni modeli

Konceptualni modeli su pojednostavljenja hidroloških procesa. Mogu se zamisliti kao spremnici između kojih se cijevima izmjenjuje voda. Agregiraju fizikalne procese u apstraktne komponente. Parametri nemaju značajno fizičko značenje i zahtijevaju značajno podešavanje.

Primjeri konceptualnih modela su SAC-SMA, HBV, GR4J, NAM.

Konceptualni modeli ne zahtijevaju previše ulaznih podataka i računalne snage, a zadržavaju relativnu dobru interpretabilnost.

Problemi leže u prenošenju na nemjerene slivove i padu performansi pri izmjenama uvjeta.

3.3 Podatkovno vođeni modeli

Podatkovno vođeni modeli povezuju ulazne podatke s izlazima bez eksplicitnog fizikalnog modeliranja, primjenom strojnog i dubokog učenja.

Više radova (Kratzert, Towards learning universal, regional, and local hydrological behaviors via machine learning applied to large-sample datasets, 2019) (Frame, 2022) (Kratzert, Toward Improved Predictions in Ungauged Basins: Exploiting the Power of Machine Learning, 2019)

pokazuje da takvi modeli mogu postići bolje točnosti od konceptualnih i procesnih modela na mjerenim i nemjerenim sljevovima te u modeliranju ekstremnih događaja.

Nedostatci su potreba za velikim količinama podataka za učenje te ograničena interpretabilnost zbog nedostatka eksplicitnih fizičkih mehanizama.

U nastavku poglavlja su navedeni neki modeli strojnog i dubokog učenja koji se mogu koristiti u predviđanju protoka rijeka.

3.3.1 Rekurentne neuronske mreže (mreže dugog kratkoročnog pamćenja)

Rekurentne neuronske mreže (engl. recurrent neural network – RNN) su dizajnirane za procesiranje serijskih podataka u kojima je poredak bitan. Za razliku od unaprijednih neuronskih mreža, RNN-i koriste povratne veze kroz koje se putem skrivenog stanja prenose informacije iz prethodnih koraka.

Osnovni RNN suočava se s problemom nestajućeg gradijenta, što otežava učenje dugotrajnih ovisnosti, a taj problem nastoje riješiti mreže dugog kratkoročnog pamćenja (engl. long short-term memory – LSTM) koje omogućuju modeliranje dugoročnih ovisnosti.

Zbog navedenih svojstava, LSTM modeli pokazali su se prikladnima za modeliranje hidroloških vremenskih serija, poput protoka rijeka na temelju dugih povijesnih podataka. Zbog toga se u posljednje vrijeme često primjenjuju u hidrologiji te često postižu vrlo dobre performanse.

3.3.2 Unaprijedne neuronske mreže (višeslojni perceptron za regresiju)

Unaprijedne neuronske mreže (engl. feedforward neural network – FNN) su neuronske mreže u kojima informacije teku u jednom smjeru, bez povratnih veza, te nemaju eksplicitnu vremensku memoriju.

Višeslojni perceptron za regresiju (engl. multilayer perceptron regression – MLPR) je slučaj FNN-a s barem jednim skrivenim slojem za predviđanje kontinuiranih vrijednosti. Slojevi MLPR-a, razliku od konvolucijskih neuronskih mreža, potpuno su povezani.

Iako MLPR modeli, zbog prisutnosti LSTM modela, više nisu toliko privlačni za modeliranje hidroloških vremenskih serija, koriste se kao referentni model u usporednim analizama.

3.3.3 Slučajne šume

Slučajne šume (engl. random forest – RF) su ansambl modeli koji treniranjem generiraju više stabala odluke, pri čemu svako daje vlastiti izlaz, a u slučaju regresije predviđanje se dobiva agregacijom izlaza svih stabala.

Za razliku od mnogih drugih podacima vođenih modela, predviđanje RF modelima daje jednostavnu interpretaciju rezultata. Jednostavni su za implementaciju što ih može činiti pogodnima za korištenje.

Iako se RF modeli mogu koristiti za hidrološka predviđanja, najčešće postižu lošije performanse od LSTM modela (Arfi, 2025).

Često se koriste kao komponenta u hibridnim modelima (Tyrallis, 2019), primjerice za predviđanje vršnog protoka (Bertoli, 2026) ili uklanjanje kolinearnosti i redundantnih značajki u ulaznim podacima (Li J. , 2024).

3.3.4 Konvolucijske neuronske mreže

Konvolucijske neuronske mreže (engl. convolutional neural network – CNN) su neuronske mreže koje, za razliku od MLP modela, koriste lokalnu povezanost i dijeljenje težina preko konvolucijskih jezgri. Time se smanjuje broj parametara i omogućuje učenje lokalnih uzoraka.

Iako LSTM modeli u hidrološkim zadacima često pokazuju bolje performanse od CNN-a (Ebtehaj, 2024.), CNN modeli se ponekad koriste u hibridnim arhitekturama (Wongchaisuwat, 2026) (Zhang, 2025) (Li X. , 2022).

3.3.5 Transformer modeli

Transformeri su suvremena kategorija neuronskih mreža temeljena na mehanizmu pažnje, koji omogućuje modelu istovremeno razmatranje odnosa između svih elemenata ulaza.

U zadacima hidroloških predviđanja, transformeri u nekim slučajevima postižu bolje performanse od LSTM modela (Liu, 2025) (Demiray, 2024) (Pölz, 2024).

3.4 Hibridne arhitekture

Hibridne arhitekture kombiniraju više modela radi iskorištavanja različitih prednosti. U takvim pristupima pojedini modeli mogu biti zaduženi za različite aspekte predviđanja, primjerice za modeliranje različitih raspona protoka, različitih vremenskih horizonata ili različitih skupova ulaznih podataka. Pojedini modeli mogu se koristiti i kao pomoćne komponente u predobradi podataka.

Odabir modela za hibridnu arhitekturu ovisi o specifičnostima problema, područja i dostupnim podacima te se najčešće određuje kombiniranjem domenskog znanja i eksperimentiranja.

Osim kombinacija unutar podacima vođenih modela, često se koriste i pristupi koji spajaju procesne i podacima vođene modele (Espinoza, 2025) (Farmani, 2026).

4. Izvori i dostupnost podataka

Glavni izvor hidroloških i meteoroloških podataka u Hrvatskoj je Državni hidrometeorološki zavod (DHMZ). Zavod prati, prikuplja i obrađuje podatke o oborinama, temperaturi zraka, relativnoj vlažnosti zraka, visini snježnog pokrivača, vodostajima, protocima i drugim meteorološkim te hidrološkim varijablama.

Na brojnim kišomjernim postajama oborine se mjere u pravilu na dnevnoj ili satnoj razini. Slično tome, temperature zraka se bilježe u dnevnim ili satnim intervalima.

Na ograničenom broju lokacija u Hrvatskoj provode se i mjerenja isparavanja, koja se najčešće agregiraju u dnevne vrijednosti, a zatim dalje u mjesečne pokazatelje.

Hidrološka mjerenja, poput protoka i vodostaja, provode se kontinuirano, ali s različitom vremenskom razlučivošću ovisno o postaji.

Za izrade meteoroloških prognoza različitih vremenskih i prostornih razlučivosti koriste se numerički modeli ALADIN-HR, ICON, ECMWF IFS, RegCM i WRF (DHMZ, n.d.).


5. Analiza i opis podataka

Izvršena je kratka analiza podataka koje je DHMZ ustupio u sklopu izrade ovoga seminara, a kod s kojim je obavljena analiza dostupan je na GitHubu (Dujmić, 2026). Dostavljeni podatci obuhvaćaju protoke rijeka mjerenih na određenim slivovima te temperature zraka i oborine na mjernim postajama na nekoliko zagrebačko-zagorskih lokacija. Cilj ove analize je uvid u neke moguće strukture, karakteristike, potencijale i nedostatke dostupnih podataka.

Tablica 1 Karakteristike vremenskih serija mjerenja

	Početak mjerenja	Kraj mjerenja	Broj zapisa	Udio nevaljalih zapisa (%)	Najčešći vremenski razmak između zapisa (s)	Broj odstupanja od najčešćeg vremenskog razmaka	Udio mjerenja bez uzastopnih ponavljanja
PROTOK [m³/s]							
Krapina-Kupljenovo	2001-01-01	2025-12-31	219178	4,01%	3600	67	41,82%
Krapina-ZlatarBistrica	2001-01-01	2024-12-31	197616	10,91%	3600	6	44,24%
Krapinica-Zabok	2001-01-01	2025-12-31	236678	0,00%	3600	17510	19,89%
OBORINE [mm]							
Krapina	2000-01-01	2025-12-31	226036	0,84%	3600	148	10,64%
Puntijarka	2000-01-01	2025-12-31	80560	2,51%	3600	355	9,79%
Varazdin	2000-01-01	2025-12-31	192186	1,50%	3600	262	9,31%
Zagreb-Maksimir	2000-01-01	2025-12-31	225658	1,01%	3600	226	9,79%
TEMPERATURA [°C]							
Krapina	2000-01-01	2025-12-31	227928	0,00%	3600	1	90,70%
Puntijarka	2000-01-01	2025-12-31	82584	0,00%	3600	5	87,91%
Varazdin	2000-01-01	2025-12-31	194951	0,06%	3600	10	91,29%
Zagreb-Maksimir	2000-01-01	2025-12-31	227928	0,00%	3600	1	91,61%

Tablica 1 prikazuje osnovne karakteristike vremenskih serija mjerenja. Dobivena mjerenja obuhvaćaju period od početka 2020. godine do kraja 2025. godine. Broj zapisa na mjernim postajama najčešće iznosi približno 220 tisuća, što odgovara kontinuiranim mjerenjima satne frekvencije. U pojedinim serijama prisutni su prekidi, što je posebno vidljivo kod mjerenja oborine i temperature na postaji Puntijarka. Navedene prekide bolje prikazuje Graf 1.



Graf 1 Temperatura kroz vrijeme na mjernoj postaji Puntijarka

Neispravni zapisi su oni za koje je zapisano vrijeme, ali je vrijednost mjerenja odsutna ili označena kao nevaljana. Broj odstupanja od najčešćeg vremenskog razmaka predstavlja nekonzistencije u vremenskim razmacima podataka. Najveći broj takvih odstupanja javlja se u podatcima protoka za sliv Krapinica-Zabok jer su podatci za 2025. godinu zapisivani u polusatnoj frekvenciji. Kod razvoja modela strojnog i dubokog učenja ovakve nekonzistentnosti vremenskih razmaka često zahtijevaju dodatnu obradu, primjerice uklanjanjem zapisa, interpolacijom ili drugim metodama ovisno o zahtjevima korištenog modela.

Pregledom podataka protoka uočena su česta uzastopna ponavljanja identičnih vrijednosti. Postoji više mogućih obrazloženja takvoga ponašanja, uključujući mjerenja u frekvenciji različitoj od satne pri čemu su nedostajući zapisi popunjavani zadnjom izmjerenom vrijednošću, ograničenu razlučivost mjernog sustava zbog koje manje promjene protoka nisu vidljive u zapisima, ili način pohrane mjerenja kod kojeg se nova vrijednost bilježi tek nakon dovoljno velike promjene mjerenja. Za potvrdu uzroka ovakvog ponašanja bilo bi potrebno dodatno savjetovanje s DHMZ-om kako bi se mogla odabrati odgovarajuća metoda obrade podataka. Nakon uklanjanja uzastopnih identičnih mjerenja ostaje približno 40 % ili 20 % zapisa, ovisno o promatranoj seriji podataka. U tako pročišćenim zapisima nije uočen jasan obrazac vremenskih razmaka mjerenja. Podaci o oborini i temperaturi ne pokazuju isti obrazac uzastopnih ponavljanja vrijednosti. Kod oborina je očekivana pojava većeg broja uzastopnih vrijednosti 0, dok se kod temperature povremena ponavljanja mogu objasniti preciznošću zapisa od jedne decimalne znamenke.

Manji broj nedostajućih ili nevaljalih zapisa moguće je nadomjestiti postupcima imputacije podataka. Pritom je potrebno uzeti u obzir mogućnost da nedostajući podaci odgovaraju periodima ekstremnih hidrometeoroloških događaja, što su upravo najbitnije točke predviđanja, a njihovo nepravilno nadomještanje bi negativno utjecalo na proces treniranja

modela. Dulji prekidi mjerenja nisu prikladni za korištenje pri treniranju, osobito ako je promatrana varijabla od visoke važnosti.

Tablica 2 Deskriptivna statistika vremenskih serija mjerenja

	Medijan	Aritmetička sredina	Standardna devijacija	Minimalna vrijednost	Maksimalna vrijednost	Kurtoza	Koeficijent asimetrije
PROTOK [m ³ /s]							
Krapina-Kupljenovo	4,61	10,19	17,43	0,55	198,17	28,33	4,74
Krapina-ZlatarBistrice	0,78	1,70	2,86	0,04	37,72	26,94	4,54
Krapinica-Zabok	0,79	1,62	2,91	0,05	53,36	45,41	5,65
OBORINE [mm]							
Krapina	0,00	0,10	0,67	0,00	65,00	791,43	19,06
Puntijarka	0,00	0,11	0,76	0,00	46,40	615,21	18,57
Varazdin	0,00	0,09	0,65	0,00	49,10	655,89	19,04
Zagreb-Maksimir	0,00	0,10	0,69	0,00	61,00	879,44	21,23
TEMPERATURA [°C]							
Krapina	11,50	11,52	9,09	-18,40	39,10	-0,62	0,06
Puntijarka	7,90	7,98	8,37	-15,90	30,90	-0,72	-0,01
Varazdin	11,70	11,45	9,08	-21,90	44,50	-0,57	0,00
Zagreb-Maksimir	12,60	12,45	9,10	-17,70	38,50	-0,65	0,02

Tablica 2 prikazuje osnovne statističke karakteristike promatranih vremenskih serija. Posebno se ističe velika varijabilnost vremenske serije protoka za sliv Krapina-Kupljenovo te visoka kurtoza protoka za sliv Krapinica-Zabok, koja sugerira prisutnost izraženijih ekstremnih događaja. Pozitivne vrijednosti koeficijenta asimetrije kod podataka protoka pokazuju da distribucija sadrži manji broj izrazito visokih vrijednosti koje značajno odstupaju od većine mjerenja. Takvo ponašanje je očekivano kod hidroloških podataka.

6. Metodološki okvir

6.1 Definicija problema

Zadatak je razviti model strojnog, odnosno dubokog učenja za hidrološko prognožiranje protoka rijeka. Cilj modela je na temelju povijesnih hidrometeoroloških podataka predvidjeti buduće vrijednosti protoka na promatranoj lokaciji.

Za razvoj modela potrebno je prikupiti odgovarajuće skupove podataka te ih pripremiti i obraditi sukladno zahtjevima odabranih modela. Pritom je potrebno obuhvatiti najmanje jedan cjelovit hidrološki ciklus, koji započinje tijekom rujna ili listopada.

Model na izlazu treba generirati prognozu protoka za promatranu točku za pet do šest dana unaprijed.


Sustav također treba omogućiti intervenciju nad vrijednostima protoka radi simulacije posebnih situacija, poput rada hidroelektrana ili havarija nasipa.

Nakon razvoja modela potrebno je provesti evaluaciju te usporediti rezultate s modelom koji je trenutačno u uporabi i/ili s jednostavnijim baznim modelom.

6.2 Odabir modela

Na temelju pregleda literature objavljene u posljednjih osam godina moguće je identificirati najzastupljenije i empirijski najuspješnije modele. Analizirano je 30 znanstvenih radova koji evaluiraju podatcima vođene modele, pri čemu su iz svakog rada izdvojeni evaluirani modeli te referentni modeli korišteni za usporedbu. Sve izlučene informacije prikazane su u poglavlju Prilog A – Izlučene informacije iz analiziranih radova.

Nakon provedene ekstrakcije podataka analizirana je učestalost pojavljivanja pojedinih modela, uključujući njihove osnovne, modificirane i hibridne varijante. Dodatno je utvrđena i učestalost primjene hibridnih modela. Modeli koji se pojavljuju višekratno te njihovi brojevi korištenja prikazani su na Graf 2.



Graf 2 Učestalost korištenja različitih modela u 30 analiziranih radova

Važno je naglasiti da analiziranih 30 radova predstavlja tek manji dio ukupnog broja istraživanja koja evaluiraju podatcima vođene modele, pri čemu bi provedba potpuno iscrpnog pregleda literature bila praktično neizvediva. Radovi su odabrani pretraživanjem relevantnih znanstvenih časopisa primjenom generičkih ključnih riječi te selekcijom prema kriteriju relevantnosti. Časopisi koji su pretraženi su HESS, Nature, Hydrological Processes, Water Resources Research, Water Resources Management, PLOS One, Results in Engineering, Journal of Environmental Management, Atmosphere, Frontiers in Water, Water Supply, Physics and Chemistry of the Earth, Journal of Water Engineering and Management, Environmental Science and Pollution Research. Iako takav pristup može uvesti pristranost prema pojedinim modelima, očekuje se da ipak daje dovoljno reprezentativan uvid u modele koji su trenutno najzastupljeniji i najrelevantniji za daljnju primjenu i evaluaciju. Pregled literature nije ukazao na postojanje univerzalno najboljeg modela primjenjivog na sve hidrološke uvjete i tipove slivova. Uspješnost pojedinog modela u značajnoj mjeri ovisi o karakteristikama dostupnih podataka, duljini vremenskih nizova, odabiru ulaznih varijabli te hidrometeorološkim specifičnostima promatranog područja. Zbog velikog broja dostupnih modela i njihovih varijanti, kao i izrazite raznolikosti scenarija u kojima su evaluirani, nije moguće donijeti jednoznačan zaključak o modelu koji bi bio optimalan za specifičan zadatak predviđanja protoka rijeka u Hrvatskoj. Stoga se kao razuman pristup predlaže evaluacija nekoliko često korištenih modela koji u literaturi konzistentno ostvaruju dobre rezultate.

Model koji se posebno ističe kao preporučljiv za implementaciju jest osnovni LSTM model, budući da je riječ o najčešće istraživanom pristupu u analiziranoj literaturi te modelu koji redovito ostvaruje performanse usporedive ili bolje od kvalitetnih procesnih, konceptualnih i drugih podacima vođenih modela korištenih kao referentni modeli. Kao referentni model preporučuje se koristiti model koji je trenutačno u uporabi na promatranom slivu, primjerice Sava Super Model 2. Dodatno je poželjno implementirati i druge podacima vođene modele, poput RF i MLPR modela, radi kvalitetnije usporedbe performansi. Nakon implementacije osnovnog LSTM modela moguće je istražiti i njegove naprednije varijante, poput više-frekventnog LSTM-a (engl. multi-frequency LSTM – MF-LSTM) i LSTM-a s očuvanjem mase (engl. mass-conserving LSTM – MC-LSTM), kao i različite hibridne pristupe. Također je moguće razmotriti primjenu suvremenijih arhitektura, poput transformerskih modela, no njihova uspješna primjena u pravilu zahtijeva vrlo velike količine kvalitetnih i konzistentnih mjerenja.

6.3 Priprema podataka

Priprema podataka predstavlja ključnu fazu razvoja modela strojnog i dubokog učenja, budući da način obrade ulaznih podataka izravno određuje performanse modela.

Ulazne varijable modela trebale bi obuhvaćati podatke koji imaju značajan utjecaj na formiranje protoka. To uključuje, kao što je ranije navedeno, oborinu, temperaturu, evapotranspiraciju, snježni pokrivač, vlažnost gornjeg sloja tla te zasićenost podzemlja. U slučaju entitetski osviještenog (engl. *entity-aware*) modela, od interesa su i statičke varijable, osobito srednja količina oborine, aridnost, površina i nadmorska visina, kao i određeni geološki i vegetacijski faktori (Kratzert, Towards learning universal, regional, and local hydrological behaviors via machine learning applied to large-sample datasets, 2019). Za svaki promatrani sliv potrebno je odabrati reprezentativne meteorološke i hidrološke postaje.

Potrebno je definirati vremensku rezoluciju, koja je najčešće dnevna ili satna, ovisno o dostupnosti podataka te o utjecaju rezolucije na trajanje treniranja i simulacije modela. Ako su vremenski razmaci mjerenja nekonzistentni ili neredoviti, interpolacijom ili drugim metodama može se dobiti satna ili druga željena rezolucija. Kod modela poput MF-LSTM može se koristiti i više vremenskih rezolucija, ovisno o predviđenom vremenskom horizontu, čime se može postići ravnoteža između prediktivne moći i brzine treniranja ili simulacije.

U procesu pripreme podataka moguće je primijeniti i dodatne transformacije ulaznih vremenskih serija. Jedan od pristupa uključuje korištenje uzastopnih razlika mjerenja umjesto apsolutnih vrijednosti. Također se mogu primijeniti filtri za uklanjanje šuma ili lokalno usrednjivanje radi smanjenja utjecaja kratkotrajnih nepravilnosti.

Zbog različitih raspona i distribucija vrijednosti varijabli, potrebno je provesti normalizaciju ili standardizaciju podataka. Jedan od mogućih pristupa je normalizacija u odnosu na povratni period ili druge hidrološki relevantne karakteristike sliva. Za varijable s izraženom asimetrijom distribucije može se primijeniti i logaritamska transformacija kako bi se smanjio utjecaj ekstremnih vrijednosti.

Prilikom podjele podataka na skupove za treniranje, validaciju i testiranje, može se koristiti kronološka podjela, pri čemu se stariji podaci koriste za treniranje, a noviji za validaciju i testiranje. Alternativno, može se primijeniti i k-struka unakrsna validacija.

6.4 Evaluacija

Raspon metrika korištenih za evaluaciju modela izrazito je širok. Iz istog skupa od 30 radova korištenih za pregled najzastupljenijih modela izdvojene su i metrike primijenjene za procjenu uspješnosti modela. U nastavku su stoga opisane evaluacijske metrike koje se najčešće pojavljuju u analiziranoj literaturi te koje se smatraju relevantnima za vrednovanje performansi modela u zadacima predviđanja protoka rijeka.

Za vrednovanje sposobnosti predviđanja hidroloških modela čak 28 od 30 analiziranih radova koristi Nash-Sutcliffe učinkovitost (engl. Nash-Sutcliffe efficiency – NSE) prikazanu izrazom 1.

$$NSE = 1 - \frac{\sum_{t=1}^T (Q_o^t - Q_m^t)^2}{\sum_{t=1}^T (Q_o^t - \overline{Q_o})^2} \quad 1$$

Q_o^t - promotreni protok u trenutku t

$\overline{Q_o}$ - aritmetički prosjek promotrenih protoka

Q_m^t - protok u trenutku t dobiven modelom

Vrijednost NSE jednaka 1 označava savršeno podudaranje predviđenih i stvarnih vrijednosti. Vrijednost 0 označava da model ostvaruje jednaku sposobnost predviđanja kao korištenje aritmetičke sredine promatranih podataka, dok negativne vrijednosti ukazuju na lošije performanse od takvog jednostavnog pristupa.

Ako vrlo negativne vrijednosti NSE predstavljaju problem ili kada je poželjno koristiti metriku ograničenu na interval između 0 i 1, moguće je koristiti normaliziranu NSE (engl. normalized NSE – NNSE) prikazanu izrazom 2.

$$NNSE = \frac{1}{2 - NSE} \quad 2$$

Kao dopuna NSE-u, često se koristi i Kling-Gupta učinkovitost (engl. Kling-Gupta efficiency – KGE), a među analiziranim radovima njih 11. Formulu prikazuje izraz 3. KGE zasebno vrednuje korelaciju između promatranih i simuliranih podataka, sustavnu pristranost modela te sposobnost reprodukcije varijabilnosti protoka. Vrijednost KGE jednaka 1 označava savršeno podudaranje predviđanja.

$$KGE = \sqrt{(r - 1)^2 + (\alpha - 1)^2 + (\beta - 1)^2} \quad 3$$

r – Pearsonov koeficijent korelacije

α - omjer standardne devijacije simuliranih i promatranih podataka

β - omjer aritmetičke sredine simuliranih i promatranih podataka

Srednja kvadratna pogreška (engl. mean squared error – MSE) se može koristiti za pridjeljivanje značajno veće kazne jako lošim predviđanjima. MSE prikazuje izraz 4.

$$MSE = \frac{1}{n} \sum_{t=1}^n (Q_o^t - Q_m^t)^2 \quad 4$$

Q_o^t - promotreni protok u trenutku t

Q_m^t - protok u trenutku t dobiven modelom

6.5 Ostali izazovi i zanimljivosti u modeliranju

Dodatni izazovi u razvoju modela odnose se na promjene u klimatskim uvjetima i dugoročne trendove poput globalnog zatopljenja. U tom kontekstu važni su pristupi poput online učenja ili periodičnog retreniranja.

Problem predstavljaju i ekstremni događaji, koji su rijetki, ali kritični za predviđanja. Zbog slabe zastupljenosti, modeli mogu slabije generalizirati u takvim uvjetima.

Interpretabilnost je također važan aspekt jer je poželjno razumjeti utjecaj ulaznih varijabli, što je otežano kod podacima vođenih modela.

Još jedan bitan faktor je računska učinkovitost, odnosno vrijeme potrebno za treniranje i predviđanje modela, što može ograničiti operativne primjene.

7. Zaključak

Pravovremeno i točno predviđanje protoka rijeka od velike je važnosti za obranu od poplava, upravljanje vodnim resursima i optimalan rad hidroelektrana. Pregled suvremene literature i analiza postojećih rješenja nedvojbeno pokazuju da modeli strojnog i dubokog učenja predstavljaju snažnu alternativu i značajno potencijalno unaprjeđenje u odnosu na tradicionalne hidrološke modele. Iako nije moguće unaprijed sa sigurnošću odrediti koji bi modeli ostvarili najbolje rezultate u specifičnim uvjetima poput hidroloških sustava u Hrvatskoj, među razmatranim pristupima posebno se ističu LSTM arhitekture, koje konzistentno postižu vrlo dobre rezultate u modeliranju vremenskih serija i predviđanju ekstremnih hidroloških događaja.

Ipak, uspješnost primjene podatkovno vođenih modela ovisi o odabiru i kvaliteti ulaznih podataka. Analiza uzorka podataka DHMZ-a ukazala je na tipične izazove iz stvarnog svijeta, poput nekonzistentnih vremenskih razmaka, nedostajućih vrijednosti i ponavljanja zapisa. To naglašava da je faza predobrade i čišćenja podataka jednako kritična kao i sam odabir modela.

Predloženi metodološki okvir pruža smjernice za daljnji razvoj sustava hidrološkog prognoziranja u Hrvatskoj. Pažljivom pripremom podataka, treniranjem odabranih modela te temeljitom evaluacijom korištenjem standardnih hidroloških metrika poput NSE i KGE moguće je razviti kvalitetne sustave predviđanja protoka.

Budući rad trebao bi biti usmjeren na praktičnu implementaciju i usporednu evaluaciju različitih modela u stvarnim uvjetima. Tek kroz eksperimentalnu primjenu na konkretnim hidrološkim podacima moguće je pouzdano utvrditi koji pristupi ostvaruju najbolje performanse u specifičnom kontekstu hrvatskih hidroloških sustava.

8. Sažetak

Ovaj rad bavi se primjenom modela dubokog učenja za predviđanje protoka i vodostaja rijeka, s naglaskom na potencijalnu primjenu i unaprjeđenje hidrološkog prognoziranja u Hrvatskoj. Tradicionalni procesni i konceptualni modeli, iako fizikalno interpretabilni, često su ograničeni računalnom zahtjevnosti. S druge strane, podatkovno vođeni modeli, posebice mreže dugog kratkoročnog pamćenja (LSTM), posljednjih godina postaju standard u hidrologiji zbog visoke točnosti, sposobnosti modeliranja dugoročnih ovisnosti te dobrih performansi na nemjerenim slivovima. U radu je provedena osnovna analiza dostupnih hidrometeoroloških podataka Državnog hidrometeorološkog zavoda (DHMZ) te opsežan pregled suvremene literature. Na temelju toga postavljen je metodološki okvir koji obuhvaća pripremu podataka, odabir arhitekture i evaluaciju. Kao glavni kandidat za razvoj novog sustava predlaže se osnovni LSTM model, uz mogućnost testiranja naprednijih hibridnih i transformerskih arhitektura, čiji bi se rezultati trebali izravno usporediti s modelima koji su trenutačno u operativnoj uporabi.

9. Literatura

- Arfi, M. (2025). Machine Learning-Based Streamflow Prediction for Hydrological Applications: A Case Study with LSTM and Random Forest . *Journal of Water Engineering and Management*, 41-42.
- Bertoli, G. (14. Siječanj 2026). A Hybrid Machine Learning Framework for Improved Short-Term Peak-Flow Forecasting.
- Demiray, B. Z. (11. Lipanj 2024). Towards Generalized Hydrological Forecasting using Transformer Models for 120-Hour Streamflow Prediction.
- DHMZ. (Svibanj 2026). *Sava Super Model 2- Sava SM2*. Dohvaćeno iz Državni hidrometeorološki zavor:
https://meteo.hr/infrastruktura.php?section=prognosticki_modeli¶m=sava_sm
- DHMZ. (n.d.). *Prognostički modeli*. Dohvaćeno iz Državni hidrometeorološki zavod:
https://meteo.hr/infrastruktura.php?section=prognosticki_modeli¶m=aladin
- Dujmić, I. (12. Svibanj 2026). *Ivan-Dujmic/FER-Presentation-Seminar*. Dohvaćeno iz GitHub: <https://github.com/Ivan-Dujmic/FER-Presentation-Seminar>
- Ebtehaj, I. (2024.). CNN vs. LSTM: A Comparative Study of Hourly Precipitation Intensity Prediction as a Key Factor in Flood Forecasting Frameworks. *Atmosphere*, 24-25.
- Espinoza, E. A. (2025). Analyzing the generalization capabilities of a hybrid hydrological model for extrapolation to extreme events. *HESS*, 1277-1278.
- Farmani, M. A. (26. Ožujak 2026). Process-Aware AI for Rainfall-Runoff Modeling: A Mass-Conserving Neural Framework with Hydrological Process Constraints.
- Frame, J. M. (2022). Deep learning rainfall–runoff predictions of extreme events. *HESS*, 3380-3383.
- Kratzert, F. (2019). Toward Improved Predictions in Ungauged Basins: Exploiting the Power of Machine Learning. *Water Resources Research*, 11348-11351.
- Kratzert, F. (2019). Towards learning universal, regional, and local hydrological behaviors via machine learning applied to large-sample datasets. *HESS*, 5096-5103.
- Li, J. (2024). Coupled intelligent prediction model for medium- to long-term runoff based on teleconnection factors selection and spatial-temporal analysis. *PLOS ONE*, 1-1.
- Li, X. (2022). Hybrid CNN-LSTM models for river flow prediction. *Water Supply*.
- Liu, J. (2025). From RNNs to Transformers: benchmarking deep learning architectures for hydrologic prediction. *HESS*, 6817-6822.
- Pölz, A. (2024). Transformer Versus LSTM: A Comparison of Deep Learning Models for Karst Spring Discharge Forecasting. *Water Resources Research*, 10-14.
- Tyralis, H. (2019). A Brief Review of Random Forests for Water Scientists and Practitioners and Their Recent History in Water Resources . *Water*.

- Wongchaisuwat, P. (2026). A hybrid CNN-LSTM approach for multi-step discharge forecasting with satellite data. *Frontiers in Water*, 2-2.
- Zhang, C. (2025). Assessing the performance and interpretability of the CNN- LSTM- Attention model for daily streamflow forecasting in typical basins of the eastern Qinghai-Tibet Plateau. *Scientific Reports*.

10. Prilozi

10.1 Prilog A – Izlučene informacije iz analiziranih radova

Zbog glomaznosti tabličnog oblika, dane su informacije u csv formatu:

Year;First author;Title;Tested models;Base models;Evaluation metrics;Conclusion (Tested vs Base)

2025;Eduardo Acuña Espinoza;Technical note: An approach for handling multiple temporal frequencies with different input dimensions using a single LSTM cell;MF-LSTM;LSTM, sMTS-LSTM, MTS-LSTM;NSE, Processing time;Positive

2025;Eduardo Acuña Espinoza;Analyzing the generalization capabilities of a hybrid hydrological model for extrapolation to extreme events;Hybrid (LSTM+HBV);LSTM, HBV;NSE, APE;Positive

2024;Grey S. Nearing;Global prediction of extreme floods in ungauged watersheds;LSTM;GloFAS (Physical);NSE, KGE, Bias, Precision, Recall, F1 score;Positive

2022;Sella Nevo;Flood forecasting with machine learning models in an operational framework;LSTM;MLR;NSE, Persistent-NSE, RMSE;Positive

2022;Jonathan M. Frame;On Strictly Enforced Mass Conservation Constraints for Modeling the Rainfall-Runoff Process;MC-LSTM;LSTM, SAC-SMA, NWM-Rv2;NSE, KGE, Pearson-r, Alpha-NSE, Beta-NSE, Peak-timing;Negative

2022;Jonathan M. Frame;Deep learning rainfall-runoff predictions of extreme events;LSTM, MC-LSTM;SAC-SMA, NWM-Rv2;NSE, KGE, Pearson-r, Alpha-NSE, Beta-NSE, FHV, FLV, FMS, Peak-timing;Positive

2021;Martin Gauch;"Rainfall-runoff prediction at multiple timescales with a single Long Short-Term Memory network";sMTS-LSTM, MTS-LSTM;LSTM, NWM;NSE, KGE, Pearson-r, Alpha-NSE, Beta-NSE, FHV, FLV, FMS, Peak-timing, MSD;Positive

2021;Pieter-Jan Hoedt;MC-LSTM: Mass-Conserving LSTM;MC-LSTM;LSTM, SAC-SMA, VIC, mHM, HBV, FUSE;NSE, Beta-NSE, FLV, FHV;Positive

2019;Frederik Kratzert;Toward Improved Predictions in Ungauged Basins: Exploiting the Power of Machine Learning;LSTM;SAC-SMA, NWM;NSE, Fractional bias, Standard deviation ratio, 95th percentile difference;Positive

2019;Frederik Kratzert;Towards learning universal, regional, and local hydrological behaviors via machine learning applied to large-sample datasets;LSTM, EA-LSTM;SAC-SMA, VIC, mHM, HBV, FUSE;NSE, alpha-NSE, beta-NSE, FHV, FMS, FLV;Positive

2018;Frederik Kratzert;A glimpse into the Unobserved: Runoff simulation for ungauged catchments with LSTMs;LSTM;NN, MLP, SAC-SMA;NSE, MSE;Positive

2018;Frederik Kratzert;"Rainfall-runoff modelling using Long Short-Term Memory (LSTM) networks";LSTM;SAC-SMA, RNN;NSE, Correlation coefficient, Variance bias, Total volume bias, FHV, FMS, FLV;Positive

2025;Jingyao Wang;Comparison of Process-Based Hydrological Modeling and Deep Learning Approaches for Streamflow Simulation;LSTM;SWAT;RMSE, NSE, Coefficient of determination;Neutral

2021;Grey S. Nearing;What Role Does Hydrological Science Play in the Age of Machine Learning?;LSTM;SAC-SMA, NWM;NSE;Positive

2024;Gülhan Özdoğan-Sariko;Physically based vs. data-driven models for streamflow and reservoir volume prediction at a data-scarce semi-arid basin;NARX;SWAT;Coefficient of determination, NSE, RMSE, NRMSE, KGE;Positive

2024;Jintao Li;Coupled intelligent prediction model for medium- to long-term runoff based on teleconnection factors selection and spatial-temporal analysis;Hybrid (RF+SVR), Hybrid (RF+MLPR);SVR, MLPR;NSE, Coefficient of determination, RMSE, MAE, MAPE, MSLE;Positive

2026;Gabriele Bertoli;A Hybrid Machine Learning Framework for Improved Short-Term Peak-Flow Forecasting;XGBoost-RF;EFAS (LISFLOOD);NSE, KGE, Peak-timing, RMSE, Correlation coefficient...;Positive

2022;Tianfang Xu;Hybrid Physically Based and Deep Learning Modeling of a Snow Dominated, Mountainous, Karst Watershed;Hybrid(UEB+ConvLSTM);LSTM, RF, SAC-SMA;Percent bias, RMSE, NSE, KGE;Positive

2023;Guillaume Cinkus;Comparison of artificial neural networks and reservoir models for simulating karst spring discharge on five test sites in the Alpine and Mediterranean regions;CNN, Conceptual;;MSE, KGE, Diagnostic efficiency;

2024;Naresh Kedam;River stream flow prediction through advanced machine learning models for enhanced accuracy;CatBoost, LGBM, RF, XGBoost;;MSE, MAE, RMSE, Coefficient of determination...;

2025;Jiangtao Liu;From RNNs to Transformers: benchmarking deep learning architectures for hydrologic prediction;11 Transformer-based models;LSTM, DLinear;KGE, NSE, Coefficient of determination, ubRMSE, FHV, FLV;Neutral

2024;Bekir Z. Demiray;Towards Generalized Hydrological Forecasting using Transformer Models for 120-Hour Streamflow Prediction;Transformer;LSTM, GRU, Seq2Seq, Persistence;NSE, KGE, Correlation coefficient, NRMSE;Positive

2021;Kei Ishida;Use of 1D-CNN for input data size reduction of LSTM in Hourly Rainfall-Runoff modeling;Hybrid (CNN+LSTM - serial);1D-CNN, LSTM, Hybrid (CNN+LSTM - parallel);NSE, RMSE, Correlation coefficient;Positive

2024;Isa Ebtehaj;CNN vs. LSTM: A Comparative Study of Hourly Precipitation Intensity Prediction as a Key Factor in Flood Forecasting Frameworks;CNN, LSTM;;Coefficient of determination, NSE, Percent bias, NRMSE...;

2026;Papis Wongchaisuwat;A hybrid CNN-LSTM approach for multi-step discharge forecasting with satellite data;Hybrid (CNN+LSTM);Correlation coefficient, NSE, RMSE, MAE;

2025;Chuchu Zhang;Assessing the performance and interpretability of the CNN-LSTM-Attention model for daily streamflow forecasting in typical basins of the eastern Qinghai-Tibet Plateau;Hybrid (CNN+LSTM+Attention);LSTM;NSE, Coefficient of determination, KGE;Positive

2022;Xia Li;Hybrid CNN-LSTM models for river flow prediction;Hybrid (CNN+LSTM);SWAT;Coefficient of determination, NSE, RE;Positive

2024;Chengqing Ren;Coupled SWAT and SWT-CNN-LSTM model to improve watershed streamflow simulation;Hybrid (SWAT+CNN+LSTM);SVM, RF, LSTM, SWAT;Coefficient of determination, NSE;Positive

2021;Ganquan Mao;Comprehensive comparison of artificial neural networks and long short-term memory networks for rainfall-runoff simulation;LSTM, ANN;FLEX-Topo;NSE, Coefficient of determination, RMSE;Positive

2025;Mehar Arfi;Machine Learning-Based Streamflow Prediction for Hydrological Applications: A Case Study with LSTM and Random Forest;LSTM;RF;RMSE, MAE, NSE, Coefficient of determination;Positive